

PS4

Programación II
Programa de Estudios Superiores
Banco de Guatemala
2025

Integrantes:

- Paulo Augusto Garrido Grijalva
- Stefani María Villeda Guerra
- Luis Daniel Monroy Rojas
- David Javier García Sutuj

Preparación de workspace

```
rm(list=ls())  
graphics.off()  
setwd("C:\\Users\\danie\\Documents\\CursoProgra_2R\\programa-II\\Tarea 4")
```

Importación de librerías

```
library(tidyverse)  
library(janitor)  
library(broom)  
library(readr)  
library(dplyr)  
library(ggplot2)  
library(knitr)
```

Para esta tarea, deberán utilizar los datos del Censo de Población de 2018, disponibles en formato CSV en: <https://censo2018.ine.gob.gt/descarga>

Limpieza y visualización de datos

```
# Carga de datos de archivo CSV  
datos <- data.table::fread(  
  "Persona - BDP.csv",  
  select = c("DEPARTAMENTO",
```

```

        "MUNICIPIO",
        "COD_MUNICIPIO",
        "PCP6",
        "PCP7",
        "ANEDUCA",
        "PEA",
        "POCUPA")
)

# Ahora cambiamos los nombres de la encuesta a unos que faciliten la
# identificación de cada campo para el futuro manejo de los datos.
colnames(datos) <- c("departamento",
                    "municipio",
                    "cod_municipio",
                    "sexo",
                    "edad",
                    "anios_educacion",
                    "pea",
                    "pocupa")

# Luego también cambiamos los nombres de los códigos de los departamentos para
# que estos se puedan visualizar en las gráficas con el nombre

datos$departamento <- recode(
  datos$departamento,
  "1" = "Guatemala",
  "2" = "El Progreso",
  "3" = "Sacatepequez",
  "4" = "Chimaltenango",
  "5" = "Escuintla",
  "6" = "Santa Rosa",
  "7" = "Solola",
  "8" = "Totonicapan",
  "9" = "Quetzaltenango",
  "10" = "Suchitepequez",
  "11" = "Retalhuleu",
  "12" = "San Marcos",
  "13" = "Huehuetenango",
  "14" = "Quiche",
  "15" = "Baja Verapaz",
  "16" = "Alta Verapaz",
  "17" = "Petén",

```

```

"18" = "Izabal",
"19" = "Zacapa",
"20" = "Chiquimula",
"21" = "Jalapa",
"22" = "Jutiapa"
)

```

1. En una tabla, muestre el número de hombres y el número de mujeres por departamento en Guatemala

```

tabla_hm <- table(datos$departamento, datos$sexo)
colnames(tabla_hm) <- c("Hombre", "Mujer")
# tabla_hm
kable(tabla_hm, caption = "Distribución por sexo y departamento")

```

Table 1: Distribución por sexo y departamento

	Hombre	Mujer
Alta Verapaz	602878	612160
Baja Verapaz	144925	154551
Chimaltenango	297154	318622
Chiquimula	199910	215153
El Progreso	87172	89460
Escuintla	365507	367674
Guatemala	1449203	1565878
Huehuetenango	557086	613583
Izabal	201859	206829
Jalapa	165871	177052
Jutiapa	237263	251132
Petén	272863	272737
Quetzaltenango	377782	421319
Quiché	455347	493914
Retalhuleu	159745	167083
Sacatepequez	161691	168778
San Marcos	501142	531135
Santa Rosa	195584	201023
Solola	201265	220318
Suchitepequez	272317	282378
Totonicapan	196293	222276
Zacapa	120239	125135

2. Utilizando **OLS**, estime el siguiente modelo:

$$td_i = \beta_0 + \beta_1 educ_i + \varepsilon_i,$$

donde td_i es la **tasa de desocupación** del municipio (número de personas desocupadas sobre la población económicamente activa) y $educ_i$ son los **años de estudio promedio** de la población económicamente activa en el municipio i .

```
# Se eliminan los datos nulos en la columna anios_de_educacion, se dejan
# los nulos en las columnas pea y pocupa
datos_sin_na <- datos |>
  filter(!is.na(anios_educacion))

# Se arma la tabla agregada por municipio con años promedio de educación
# y tasa de desocupación
df_municipios <- datos_sin_na |>
  group_by(municipio) |>
  summarise(
    #total = n(),
    td = round( sum(!is.na(pocupa)) / sum(!is.na(pea)), 4),
    educ = mean(anios_educacion)
  )
head(df_municipios, 5)
```

```
# A tibble: 5 x 3
  municipio    td  educ
  <int> <dbl> <dbl>
1     101 0.965  8.41
2     102 0.967  7.81
3     103 0.971  6.82
4     104 0.965  5.41
5     105 0.977  4.92
```

```
# formula para el modelo de regresión
formula_modelo <- td ~ educ
modelo <- lm(formula_modelo, data = df_municipios)
summary(modelo)
```

Call:

```
lm(formula = formula_modelo, data = df_municipios)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.104734	-0.008283	0.003300	0.011259	0.026392

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.9800074	0.0036393	269.285	<2e-16 ***
educ	-0.0012793	0.0007562	-1.692	0.0916 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01667 on 338 degrees of freedom

Multiple R-squared: 0.008396, Adjusted R-squared: 0.005462

F-statistic: 2.862 on 1 and 338 DF, p-value: 0.09163

3. Cree un **diagrama de dispersión** para mostrar la relación entre td_i y $educ_i$, e incluya en la figura la **gráfica de ajuste de la regresión** del punto anterior.

```
# Diagrama de dispersión de años de educación y tasa de desocupados
plot_dispersion <- df_municipios |>
  ggplot(aes(x = educ, y = td)) +
  geom_point(color = "dodgerblue4", size = 2, alpha = 0.5) +
  geom_smooth(color = "firebrick3", linewidth = 1.2) +
  scale_x_continuous(
    breaks = seq(0, 10, by = 1)
  ) +
  labs(
    title = "Regresión OLS: tasa de desocupados ~ educación",
    subtitle = "Datos agregados por municipio",
    y = "Tasa de desocupados %",
    x = "Años promedio de educación"
  ) +
  theme_minimal()+
  theme(
    plot.title = element_text(size = 16, face = "bold", hjust=0.5),
    plot.subtitle = element_text(size = 14, hjust = 0.5),
    axis.title.x = element_text(size = 12),
    axis.title.y = element_text(size = 12),
    axis.text.x = element_text(angle = 0, hjust = 1),
    legend.position = "top"
  )
plot_dispersion
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'




Figure 1: Diagrama de dispersión años de educación y tasa de desocupados”

4. Gráfica de *Pirámide de población* % de datos a nivel nacional

```
# Piramide de población %. Datos a nivel nacional por edades distinguiendo entre
# hombres (1) y mujeres (2)
df_edades <- datos |> select(edad, sexo) |> filter(!is.na(edad))
total_obs = nrow(df_edades)

df_edades <- df_edades |>
  mutate(
    grupo_edad = cut(x = edad,
                     breaks = c(seq(0, 100, by = 5), Inf),
                     right = FALSE,
                     include.lowest = TRUE,
                     labels = c(paste(seq(0, 95, by = 5),
                                       seq(4, 99, by = 5),
                                       sep = "-"),
                               ),
                     "100 o más")
```

```

    )
  )
) |> group_by(grupo_edad) |>
summarise(
  hombres = sum(sexo == 1) / total_obs,
  mujeres = sum(sexo == 2) / total_obs
)

df_piramide <- df_edades |>
  pivot_longer(
    cols = c(hombres, mujeres),
    names_to = "sexo",
    values_to = "porcentaje"
  ) |>
  mutate(
    porcentaje = ifelse(sexo == "hombres", -porcentaje, porcentaje) # hombres a la izqu
  )

plot_piramide <- ggplot(df_piramide, aes(x = porcentaje, y = grupo_edad, fill = sexo)) +
  geom_bar(stat = "identity", width = 0.9) +
  scale_x_continuous(
    labels = scales::percent_format(accuracy = 1),
    breaks = seq(-0.06, 0.06, by = 0.02) # ajusta según tus proporciones
  ) +
  scale_fill_manual(values = c("hombres" = "dodgerblue2", "mujeres" = "indianred")) +
  labs(
    title = "Pirámide de población (%)",
    subtitle = "Datos a nivel nacional",
    x = NULL,
    y = "Edades",
    fill = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(size = 16, face = "bold", hjust = 0.5),
    plot.subtitle = element_text(size = 12, hjust = 0.5),
    axis.text.x = element_text(size = 10),
    axis.text.y = element_text(size = 10),
    legend.position = "top"
  )
plot_piramide

```




Figure 2: Pirámide de población (%)